НЕ ФИНАЛЬНАЯ ВЕРСИЯ — WORK IN PROGRESS

Лекция 04.09.2026

База данных - организованная структурированная совокупность данных, хранящиеся в памяти ЭВМ и отображающих состояние объектов

Модель данных - набор концепций правил и структур, которые определяют как организуются хранятся и обрабатываются данные

СУБД - комплекс программных средств предназначенный для создания ведения и совместного использования БД.

Выбор модели данных критически важен – от него зависит производительность, гибкость

Лекция 11.09.2026

Реляционная БД:

Особенности реляционных БД:
- организует данные в виде двумерных таблиц
- Используют структурированный язык запросов SQL
- ACID - свойства

Про ACID:
1) Атомарность (Atomicity): Транзакция выполняется либо полностью, либо не выполняется вообще. Промежуточных результатов не бывает.
2) Согласованность (Consistency): База данных всегда переходит из одного корректного состояния в другое, не нарушая правила системы.
3) Изоляция (Isolation): Параллельные транзакции не влияют друг на друга; их результат выглядит так, будто они шли по очереди.
4) Устойчивость (Durability): Если транзакция успешно завершилась, изменения не пропадут, даже если случится сбой питания или системы

Преимущества:
- Благодаря механизму ключей, ограничений и транзакций, обеспечивается целостность и непротиворечивость данных.
- Использование SQL как стандарта облегчает разработку и поддержку приложений, а также миграцию данных между системами
- Процесс нормализации позволяет устранить избыточность данных и аномалии.

Недостатки:
- Изменение структуры таблиц на работающей системе может быть сложной и дорогой операцией.
- Горизонтальные масштабирование реляционных баз данных зачастую сложнее реализовать по сравнению с некоторыми NoSQL решениями.
- Сложные JOIN-запросы на огромных таблицах могут выполняться медленно.
- Неэффективна для хранения иерархических (древовидных) или графовых данных.

Два вида запросов:
- OLAP (Online Analytical Processing)
- OLTP (Online Transaction Processing)

Колоночная

Особенности:
- Вместо того чтобы хранить каждую запись целиком, данные организуются по столбцам.
- Реляционная таблица: строки и столбцы
- Фиксированная схема
- OLAP

Wide-column NoSQL
1) Масштабируемость записи
2) горизонтальная масштабируемость

Документоориентированная
- Данные хранятся в виде документов, а не в виде строк таблицы.
- Относятся к семейству NoSQL.
- Документы обычно представляют собой структуры в формате BSON
- Документы объединяются в коллекции (аналогичны таблицам, но без обязательного соответствия единой схеме для всех записей).
- Документы могут содержать вложенные объекты и массивы.
- Данные в виде агрегатов.
- Горизонтально масштабируема.

Графовая
- Вместо таблиц - ноды, связи, свойства. Каждый узел - json.
- Скейлинг по горизонтали.
- Нет жестко фиксированной схемы.
- Узкоспециализированная БД, недостатков нет
- Соц сети, рекомендации, цепочки поставок, базы знаний.

K-V БД
- Похожи на документоориентированные.
- Данные организованы в виде пар ключ-значение.
- Значение может быть любым.
- Высокая производительность, низкая надежность + низкая агрегация.

Timeseries (Временные ряды)
- Данные упорядоченные по времени.
- Высокая скорость записи + агрегации и интерполяции.
- Узкоспециализированная.

Векторная
- Данные хранятся в виде векторов вещественных чисел (ML-задачи).
- Оптимизация через спец индексы и прочие ML-штуки.

Хранилище данных

- предназначены для работы с файлами, такими как документы, изображения, видео, аудио файлы
- располагаются в каталогах и подкаталогах.
- Хранит помимо файла – метаданные
- Доступ к файлам осуществляется по их именам и путям в файловой системе
- Необходимо так как в обычных БД размер кортежа ограничен. Поэтому в БД не хранят файлы

Лекция 18.09.2026

Погружение в реляционные СУБД

- Отношение (табличка) – фиксированный набор (множество) атрибутов, каждый из которых определен на некотором домене. Изменяемое множество кортежей, соответствующих заголовку. Каждый кортеж содержит множество значений атрибутом.
  - Отношение не упорядочено
  - Атрибуты не упорядочены (?)
  - Все кортежи уникальны (В SQL не обязательно)
- Атрибут (строчка) – именованная характеристика или свойство некоторого объекта, информация о котором хранится в отношении. Каждый атрибут определяется на некотором домене. Домен - это множество всех допустимых значений атрибута.
  - У каждого атрибута свое уникальное имя внутри таблицы (отношения).

  Виды атрибутов:
  - Простой
  - Составной
  - Однозначный
  - Многозначный
  - Производный

  В SQL допустимы только простые однозначные атрибуты. Иначе нарушаются нормальные формы, что приводит к противоречивости данных. Тогда если атрибуты в таблице не однозначные простые — ошибка в проектировании.

  > **Важно понимать про атрибуты**
  >
  > - В реляционной модели допустимы только простые однозначные атрибуты
  > - Составные атрибуты при переходе к реляционной модели разбиваются на отдельные столбцы или выносятся в отдельную таблицу
  > - Многозначные атрибуты выносятся в отдельную таблицу и связываются с основной через внешний ключ
  > - Производные атрибуты обычно не хранятся в базе, а вычисляются в запросах или представлениях. (могут храниться для оптимизации)

- Кортеж (колонка)

Definition

Домен - это множество всех допустимых значений атрибута.

- Тип Данных + ограничение
- Целостность данных.
- Согласованность

Целостность - набор правил, которым должны удовлетворять данные, чтобы соответствовать предметной области. Это требования к данным. Согласованность - состояние БД, при котором все ограничения целостности выполнены. То есть данные не противоречивы.

Целостность бывает:

- Доменной (смысловая)
- Целостность сущностей
- Ссылочная
- Пользовательская

Важные определения

- Степень отношения (арность) – количество атрибутов в отношении
- Кардинальность отношения — количество кортежей в отношении
- Кардинальность атрибута — количество уникальных значений атрибута
- Селективность — принимает от 0 до 1 , кардинальность атрибута / кардинальность отношения. Если селективность близка к 1 – большая часть значений уникальная, хорошая оптимизация через индексацию. И наоборот, если близка к 0 — атрибуты это switch-и (например мужской/женский пол). Нет смысла оптимизировать.

Еще важные определения

- Суперключ – некий набор атрибутов, по которому можно уникально идентифицировать запись. Их может быть много
- Потенциальный ключ – подмножество суперключа, минимальный набор атрибутов, который нужен для уникальной идентификации кортежа.
- Первичный ключ – СУБД проверяет что не NULL и что уникален, желательно чтобы не менять. На этот ключ накладывается constrains.
- Внешний ключ — ссылка на первичный ключ.
- Альтернативный ключ - потенциальный ключ, который не был выбран в качестве Первичного.

Типы Primary Key

- Естественный ключ – хранит характеристику объекта
- Суррогатный ключ – значение не связанное с объектом, поэтому не измется – ведь оно ничего не значит. Лучше использовать их (неизменяемость). Бывают:
  - Целочисленный
  - Uuid. Хорошая идея, когда:
    - Микросервисы
    - Генерация на front.
- Простой ключ – состоит из одного атрибута
- Составной ключ - взяты несколько атрибутов, из них сделан PK. Плохо, так как внешние ключи в других таблицах будет иметь также несколько атрибутов, накладные расходы увеличены.

Типы данных (в SQL)

- Целочисленный (smallint, int, bigint)
- Floating point (real, double)
- Строки (varchar, char, text)
- Дата и время (date, time, timestamp, interval)
- Логические (bool)
- Геометрические типы (point,path,line)
- json

Целочисленные типы (в SQL)

- Фиксированные (smallint, int, bigint)
- DECIMAL(M,D)
- Floating Point
- Денежный
- Автоинкрементирующиеся

Биты (в SQL)

- BIT(n)
- VARBIT - переменной длины
- BOOLEAN - TRUE,FALSE,NULL.

Строки (в SQL)

- char(n) – строка фиксированной длины
- varchar – переменной длины
- text – строковые данные без ограничения длины
- bytea – двоичные данные без ограничения длинны

Дата и время (в SQL)

- TIMESTAMP [без часового пояса]
- TIMESTAMPZ [с часовым поясом]
- DATE
- TIME [без часового пояса]
- TIME [с часовым поясом]
- INTERVAL

- DDL- Data definition language
- DML - Data manipulation language

Основные команды DDL

- CREATE TABLE
- ALTER TABLE
- DROP
- TRUNCATE

Основные команды DML

- SELECT
- INSERT
- UPDATE
- DELETE
- MERGE

Логический порядок выполнения:

1) WITH
2) FROM
3) WHERE
4) GROUP BY
5) HAVING
6) WINDOW
7) SELECT (вычисление выражений | DISTINCT)
8) UNION/INTER/EXCEPT
9) ORDER BY
10) LIMIT/OFFSET/FETCH
11) FOR UPDATE

WITH - именованный подзапрос, рекурсивные подзапросы / оптимизация. А-ля функция.

При удалении больших объемов данных, TRUNCATE лучше DELETE (меньше записей в журнале записей, не проверяет данные, сразу удаляя их).

Лекция 25.09.2026

Реляционная алгебра

Типы операций:

- Теоретико-множественные (объединение, разность, пересечение, дек. произведение)
- Специальные реляционные (выборка σ, проекция π, соединение , деление $\%$)

Лекция 02.10.2026

Нормализация

Дублирование $\neq$ избыточность. Избыточность — вероятность получить аномалии. Дублирование может быть нормальным, а избыточность — нет. Избыточность — данные хранятся несколько раз, но при этом эти данные можно получить из другого места. Пример: возраст, его можно получить из даты рождения. Пример дублирования: user_id.Их несколько, но нельзя получить из другого места.

Тут слайды из презы про степени нормализации

Лекция 09.10.2026

Транзакции

Транзакция – некоторая последовательность операций, которая выполняется как единое целое. Транзакция либо завершается успешно (COMMIT), либо полностью отменяется (ROLLBACK), чтобы гарантировать целостность данных. Свойства транзакции (ACID):

1) Атомарность (Atomicity): Транзакция выполняется либо полностью, либо не выполняется вообще. Промежуточных результатов не бывает.
2) Согласованность (Consistency): База данных всегда переходит из одного корректного состояния в другое, не нарушая правила системы.
3) Изоляция (Isolation): Параллельные транзакции не влияют друг на друга; их результат выглядит так, будто они шли по очереди.
4) Устойчивость (Durability): Если транзакция успешно завершилась, изменения не пропадут, даже если случится сбой питания или системы

Ограничения целостности:

- NUT NULL
- UNIQUE
- Primary Key
- Foreign key
- CHECK
- EXCLUSION CONSTRAINS

Isolation

Изоляция транзакций:

- READ UNCOMMITED - Позволяет читать даже не завершенные изменения других транзакций (не используется в Posgre)

- READ COMMITED (по умолчанию) — Транзакция видит только зафиксированные (COMMIT) изменения других транзакций.
- REPEATABLE READ — Транзакции вдят данные в том виде, в каком они были на моменте её начала, даже если другие транзакции вносят изменения
- SERIALIZABLE — Максимальный уровень изоляции. Гарантирует

Виды аномалий:
- Потерянное обновление
- Dirty Read
- Nonrepeatable Read
- Phantom Read
- Serialization Anomaly
- Циклическая зависимость данных (Write Skew)

Проверка на аномалии – NP полная задача, поэтому полную блокировку (Предикатную) не используют. На практике используется:
- Блокировка диапазонов ключей: Наиболее распространенная практика. При сканировании диапазона транзакция блокируется не только существующие записи, но и «промежутки» между ними, а также запись, следующую за диапазоном. Это предотвращает вставку новых записей внутрь заблокированного диапазона.
- Блокировка индексов или страниц: Более грубый подход – блокировка целых страниц индекса или даже таблиц, что гарантирует отсутствие фантомов, но ценой снижения производительности.

PostgreSQK испрользует оптимистичный подход, основанный на Serializable Snapshot Isolation.

Durability

Write-Ahead Logging

стратегия, при которой все изменения данных сначала записываются в журнал, и только потом применяются к основным файлам баз данных.

Структура WAL:
- Header (24 байта)
- Page ID (8 байт)
- Old Data (размер страницы)
- New Data (размер страницы)
- Checksum (8 байт)

Работает не всегда, и зависит от конфигурации PostgreSQL:
- fsync = on — при отключении WAL файл хранится в оперативной памяти.
- synchronous_commit = on — при отключении, данные будут в асинхронном режиме (подтверждение коммита будет отправлено до записи на диск)
- wal_buffers = …MB

Checkpoint — процесс при котором все измененные данные из буферного кэша сбрасываются на диск, создавая согласованное состояние БД.

Multi-Version Concurrency Control (MVCC)

Механизм для изоляции транзакций, но с минимальным количеством блокировок (для параллельной работы) [возможно нуждается в правках] Условно: В каждой таблице создается несколько доп атрибутов, важные для MVCC: $x_{\min}$— номер транзакции при котором запись была внесена и $x_{\max}$. — номер транзакции при которой запись была удалена. Тогда для проверки существует ли запись, транзакции нужно проверить что $x_{\min} >$ текущего номера, а $x_{\max} <$ текущего номера.? Тогда SELECT просто проверяет это неравенство, INSERT создаст новую запись куда присвоит свой номер атрибуту $x_{\min},$) DELETE поставит свой номер в значение $x_{\max}$, а UPDATE установит в $x_{\max}$ старой записи свой номер, и создаст новую запись с $x_{\min} =$ текущий номер.

Лекция 16.10.2026

Индекс - объекты базы данных, предназначенные для ускорения поиска и выборки строк из таблицы, минимизируя количество данных, которые нужно просматривать. Также индексы служат для поддержания некоторых ограничений целостности.

Как устроены? Устанавливает соответствие между ключем и строками таблицы, в которых этот ключ встречается. Строки идентифицируются с помощью TID (tuple ID).

Однако проблема - увеличение затрат на запись.

Типы индексов;
- Btree
- Hash
- GIN
- GiSt
- SP-Gist
- BRIN

[Здесь должно быть объяснение всех индексов до BRIN]

Лекция 23.10.2026

LSM-Tree

[Здесь должно быть объяснение LSM-Tree] Архитектура PGS Ролевая модель